Actividad Práctica: "Despliegue y Análisis Comparativo de Familias de Aprendizaje Supervisado"

Curso: Inteligencia Artificial

Modalidad: Trabajo en Equipo (6 Equipos)

Entregables: Informe en PDF con documento Técnico + Código Fuente (Repositorio/ Python) + Simulación Interactiva

Objetivos de la Actividad

1. **Modelado Matemático:** Comprender la formulación teórica, función de pérdida y/o criterio de optimización de tres modelos de aprendizaje supervisado asignados.
2. **Simulación y Experimentación:** Implementar, entrenar y evaluar los modelos en conjuntos de datos representativos, ajustando sus hiperparámetros.
3. **Aplicación Práctica:** Analizar casos de uso reales donde la familia y los modelos seleccionados aporten un valor diferencial.

Asignación de Modelos por Equipos y Familias

Cada equipo trabajará con **3 modelos** pertenecientes a familias específicas del aprendizaje supervisado:

[Familia 1: Árboles y Ensembles] ---> Equipo 1 y Equipo 2

[Familia 2: Basados en Margen/Instancias] ---> Equipo 3 y Equipo 4

[Familia 3: Probabilísticos y Estructurados] ---> Equipo 5 y Equipo 6

Familia 1: Árboles de Decisión y Métodos de Ensamble

Foco: División jerárquica del espacio de características y combinación de clasificadores débiles.

- **Equipo 1:**
    1. Árboles de Decisión (CART / C4.5)
    2. Random Forest (Bagging)
    3. Gradient Boosting Decision Trees (GBDT - XGBoost/LightGBM)
- **Equipo 2:**
    1. Extra Trees (Extremely Randomized Trees)
    2. AdaBoost (Adaptive Boosting)

3. CatBoost (Boosting optimizado para variables categóricas)

Familia 2: Modelos Basados en Márgenes y Distancias (Instancias)

Foco: Geometría del espacio de características, métricas de distancia y optimización de hiperplanos.

- **Equipo 3:**
    1. Máquinas de Vectores de Soporte para Clasificación (SVC)
    2. Máquinas de Vectores de Soporte para Regresión (SVR)
    3. k-Vecinos Más Cercanos (k-NN)
- **Equipo 4:**
    1. SVM con Kernel RBF / Gaussiano
    2. Soft-Margin SVM (Con variables de holgura ξ_i)
    3. Radius Neighbors / Weighted k-NN

Familia 3: Modelos Probabilísticos y Redes Neuronales Multicapa

Foco: Estimación de distribuciones de probabilidad condicional y aproximación de funciones no lineales.

- **Equipo 5:**
    1. Naive Bayes Gaussiano
    2. Perceptrón Multicapa para Clasificación (MLP Classifier)
    3. Regresión por Proceso Gaussiano (Gaussian Process Regression)
- **Equipo 6:**
    1. Naive Bayes Multinomial / Complement
    2. Perceptrón Multicapa para Regresión (MLP Regressor)
    3. Discriminante Lineal y Cuadrático (LDA / QDA)

Estructura Requerida para el Informe Técnico

Cada equipo deberá desarrollar su entrega bajo los tres pilares fundamentales solicitados:

1. Fundamentos Matemáticos y Teóricos

Para cada uno de los 3 modelos asignados, el equipo debe detallar:

- **Formulación del modelo:** Ecuación representativa / hipótesis $h_\theta(x)$.
- **Criterio de optimización:** Función de pérdida (Loss Function), ganancia de información (Entropía/Gini), o función de costo a minimizar/maximizar.
- **Algoritmo de aprendizaje:** Método de resolución (p. ej., Gradiente Descendente, Programación Cuadrática, Backpropagation, Algoritmo Greedy).

2. Simulación y Experimentación (Código)

- **Preprocesamiento:** Escalado de datos, manejo de variables categóricas y división entrenamiento/prueba.
- **Simulación:** Implementar una búsqueda de hiperparámetros (GridSearchCV o RandomizedSearchCV).
- **Evaluación de Desempeño:** Calcular y comparar métricas clave (Matriz de confusión, Precision, Recall, F1-Score, ROC-AUC, RMSE, R^2 según corresponda).
- **Visualización:** Gráficas de fronteras de decisión (en 2D/3D), curvas de aprendizaje o importancia de características (*Feature Importance*).

3. Aplicaciones y Casos de Uso

- Presentar un caso de estudio real para cada modelo (ej. detección de fraudes, diagnóstico médico, predicción de demanda).
- Justificar técnicamente por qué el modelo es adecuado para dicha aplicación (sensibilidad a *outliers*, interpretabilidad, costo computacional, etc.).

Rúbrica de Evaluación

Criterio	Descripción	Puntaje
Rigor Matemático	Explicación clara y formal de las ecuaciones, funciones de pérdida y supuestos de los 3 modelos.	35%
Simulación y Código	Código limpio, reproducible, con ajuste de hiperparámetros y métricas de evaluación bien justificadas.	35%
Análisis de Aplicaciones	Calidad del análisis crítico sobre la aplicabilidad real y comparativa entre los 3 modelos.	20%
Conclusiones y Presentación	Claridad en la exposición y discusión de resultados.	10%