ACTIVIDAD PRÁCTICA · INTELIGENCIA ARTIFICIAL

Árboles de decisión y métodos de ensamble

Comparación experimental de CART, Random Forest y XGBoost

Equipo 1

Informe técnico · Modelado matemático · Simulación · Análisis de aplicaciones

Objetivo

Formular y comparar tres algoritmos supervisados de la familia de árboles utilizando un protocolo reproducible de clasificación binaria. El proyecto incluye los criterios de aprendizaje, el ajuste de hiperparámetros, la evaluación en datos no usados para entrenar y una aplicación interactiva.

Conjunto experimental: Breast Cancer Wisconsin (Diagnostic), repositorio UCI Machine Learning Repository. Las métricas y conclusiones de este informe se generan desde la ejecución guardada en la carpeta results.

Fecha de generación: 27 de octubre de 2026

Resumen ejecutivo

Se compararon CART, Random Forest y XGBoost con 569 observaciones y 30 variables. El mejor ROC-AUC en el conjunto de prueba fue 0.996, obtenido por Random Forest. Sus métricas para la clase positiva maligno fueron precision 1.000, recall/sensibilidad 0.929 y F1 0.963. Este resultado describe únicamente esta partición de prueba y no representa rendimiento clínico.

La comparación ilustra tres estrategias diferentes: un árbol CART es interpretable pero puede variar mucho con cambios en los datos; Random Forest promedia árboles aleatorizados para reducir varianza; XGBoost añade árboles secuencialmente y optimiza una pérdida con regularización. Se mantuvieron las mismas filas de prueba para los tres modelos.

1. Fuente y descripción del conjunto de datos

La fuente original es Breast Cancer Wisconsin (Diagnostic), UCI Machine Learning Repository [1]. La ficha de UCI describe 569 muestras, 30 características numéricas y una variable de diagnóstico; las mediciones se calcularon a partir de imágenes digitalizadas de aspiración con aguja fina (FNA) y describen núcleos celulares. La ficha informa que no hay valores faltantes. El conjunto fue donado a UCI el 31 de octubre de 1995.

Se cargó la copia que distribuye scikit-learn mediante sklearn.datasets.load_breast_cancer, que la documenta como una copia del conjunto UCI y expone una matriz de 569 × 30 [2]. El archivo data/dataset.csv conserva las 30 variables numéricas y la etiqueta recodificada; se excluye cualquier identificador, pues no es una variable predictiva. La etiqueta de scikit-learn usa 0=maligno y 1=benigno; se invirtió a 1=maligno (positivo) y 0=benigno para que recall y falsos negativos se interpreten de forma directa.

En la copia analizada hay 357 casos benignos y 212 malignos. El conjunto completo no se presenta como un conjunto clínico representativo de la población actual; es una referencia académica pequeña y tabular.

2. Preparación de datos y protocolo experimental

Se realizó una partición estratificada, con semilla fija 42: 455 filas para entrenamiento (80%) y 114 para prueba (20%). Estratificar conserva aproximadamente la prevalencia de ambas clases. La prueba se mantuvo fuera de la selección de parámetros y se usó una sola vez para calcular el resultado final.

Sobre el entrenamiento se aplicó RandomizedSearchCV con 20 combinaciones aleatorias por modelo y validación cruzada estratificada de 5 pliegues (semilla 42). El criterio de selección fue ROC-AUC promedio. Cada búsqueda volvió a ajustar el mejor estimador sobre todo el conjunto de entrenamiento. La clase positiva y el umbral final se fijaron antes de observar los resultados: maligno y 0.5, respectivamente.

No se normalizaron las variables: los modelos basados en árboles eligen umbrales de partición y no dependen de la escala euclidiana. Se verifican datos faltantes (UCI reporta ninguno). No se emplearon transformaciones aprendidas del conjunto completo, evitando fuga de información.

Configuración explorada: CART (criterio Gini/entropía/log-loss, profundidad, mínimo de muestras por división/hoja y poda ccp_alpha); Random Forest (200–700 árboles, máximo de variables, profundidad, mínimo de hoja/división, bootstrap y ponderación de clases); XGBoost (100–500 árboles, tasa de aprendizaje, profundidad, peso mínimo de hoja, subsampling de filas y variables, regularización L2 y gamma). La combinación aleatoria concreta y ganancia de validación se registran en results/mejores_parametros.json.

3. Fundamentos matemáticos

3.1 Árbol de decisión CART

CART (Classification and Regression Trees) construye un árbol binario. Cada nodo interno evalúa una regla del tipo $x_j \leq t$; las hojas asignan una clase (o estiman una probabilidad). El aprendizaje es voraz: en

cada nodo se elige la partición que más reduce la impureza ponderada, sin buscar exhaustivamente el árbol global óptimo [3, 4].

$$\text{Gini}(D) = 1 - \Sigma_k\, p_k^2 \cdot \text{Entropía}(D) = -\Sigma_k\, p_k \log_2(p_k)$$

Para una división en subconjuntos D_l y D_r, la ganancia es $I(D) - (|D_l|/|D|)I(D_l) - (|D_r|/|D|)I(D_r)$. En clasificación binaria, p_k es la proporción de ejemplos de la clase k en el nodo. Los parámetros de profundidad, mínimo de hoja y ccp_alpha limitan la complejidad y regularizan el sobreajuste. El algoritmo busca óptimos locales mediante búsquedas de umbrales; no garantiza el árbol global óptimo.

3.2 Random Forest: bagging de árboles

Random Forest entrena T árboles con muestras bootstrap independientes: cada muestra se obtiene con reemplazo del entrenamiento. En cada nodo, el árbol considera además una selección aleatoria de variables. Para clasificación se combinan votos o probabilidades; aquí se usa el promedio de probabilidades estimadas por hoja [5].

$$\hat{p}(y=1 \mid x) = (1/T)\, \Sigma_{t=1}^{T}\, \hat{p}_t(y=1 \mid x)$$

El promedio de árboles correlacionados imperfectamente tiende a reducir la varianza de un árbol individual. La aleatorización de filas y variables busca disminuir su correlación; no elimina el sesgo y puede reducir la interpretabilidad global. No se realiza una secuencia correctiva de errores: a diferencia de boosting, los árboles pueden entrenarse en paralelo.

3.3 Gradient Boosting Decision Trees con XGBoost

XGBoost es un método de boosting aditivo. En cada iteración agrega un árbol que mejora el ajuste de las predicciones anteriores; los árboles se entrenan secuencialmente. Para clasificación binaria se suma una función de puntuación y se transforma con la función sigmoide [6].

$$F_m(x) = F_{m-1}(x) + \eta\, f_m(x) = \Sigma_{t=1}^{m}\, \eta\, f_t(x) \cdot \hat{p}(y=1|x)=1/(1+\exp(-F_m(x)))$$

La función objetivo combina la pérdida logística con penalización de complejidad: $\text{Obj} = \Sigma_i\, \ell(y_i, F(x_i)) + \Sigma_t\, \Omega(f_t)$, donde $\Omega(f) = \gamma T + (\lambda/2)\Sigma_j w_j^2$. T es el número de hojas y w_j sus puntuaciones. Para $y \in \{0,1\}$, $\ell = -[y \log(p) + (1-y)\log(1-p)]$. XGBoost aproxima el objetivo por una expansión de Taylor de segundo orden y usa gradientes y hessianos para puntuar divisiones; γ, λ, profundidad, tasa η y subsampling controlan capacidad y regularización. La tasa η escala la contribución del árbol añadido.

Las implementaciones representan estrategias diferentes: CART usa particiones voraces; Random Forest agrega modelos con bagging y aleatorización; XGBoost minimiza iterativamente el error residual en el espacio de funciones. El resultado depende de los datos, el criterio y los hiperparámetros, no hay un ganador universal.

4. Métricas de evaluación

La matriz de confusión se cuenta con maligno como clase positiva: TP son malignos correctamente detectados, FN malignos clasificados como benignos, FP benignos clasificados como malignos y TN benignos correctamente clasificados. Un FN puede ser especialmente costoso en un contexto de cribado, por lo que recall se interpreta junto con precisión y falsos positivos; no se optimizó ni modificó un umbral clínico.

$$\text{Recall} = TP/(TP+FN) \cdot \text{Precision} = TP/(TP+FP) \cdot F1 = 2 \cdot \text{Precision} \cdot \text{Recall}/(\text{Precision}+\text{Recall})$$

ROC-AUC resume la capacidad de ordenar positivos por encima de negativos en distintos umbrales; no es exactitud ni sustituye la sensibilidad en un umbral operativo. Exactitud balanceada = (sensibilidad + especificidad)/2. También se muestra exactitud global, pero esta métrica sola puede ocultar errores en la clase minoritaria.

5. Resultados medidos

La siguiente tabla corresponde exclusivamente al conjunto de prueba reservado. ROC-AUC de validación cruzada se informa aparte y sirvió para seleccionar hiperparámetros.

Modelo	ROC-AUC prueba	Precision maligno	Recall maligno	F1 maligno	Exactitud	Bal. exactitud
CART	0.975	1.000	0.929	0.963	0.974	0.964
Random Forest	0.996	1.000	0.929	0.963	0.974	0.964
XGBoost	0.992	1.000	0.929	0.963	0.974	0.964

CART — matriz de confusión (filas: clase real; columnas: predicción; orden benigno, maligno): [[TN=72, FP=0], [FN=3, TP=39]]. ROC-AUC CV=0.956; tiempo de ajuste 2.31 s (dependiente del hardware).

Random Forest — matriz de confusión (filas: clase real; columnas: predicción; orden benigno, maligno): [[TN=72, FP=0], [FN=3, TP=39]]. ROC-AUC CV=0.990; tiempo de ajuste 303.95 s (dependiente del hardware).

XGBoost — matriz de confusión (filas: clase real; columnas: predicción; orden benigno, maligno): [[TN=72, FP=0], [FN=3, TP=39]]. ROC-AUC CV=0.994; tiempo de ajuste 44.59 s (dependiente del hardware).

Los parámetros seleccionados por CV y la ROC-AUC promedio aparecen debajo. La métrica de CV no debe confundirse con la puntuación final de prueba.

CART: ROC-AUC CV = 0.9556; parámetros = {"min_samples_split": 15, "min_samples_leaf": 2, "max_depth": null, "criterion": "entropy", "ccp_alpha": 0.0005}

Random Forest: ROC-AUC CV = 0.9899; parámetros = {"n_estimators": 500, "min_samples_split": 5, "min_samples_leaf": 2, "max_features": "sqrt", "max_depth": null, "class_weight": "balanced_subsample", "bootstrap": false}

XGBoost: ROC-AUC CV = 0.9942; parámetros = {"subsample": 1.0, "reg_lambda": 1, "n_estimators": 200, "min_child_weight": 1, "max_depth": 2, "learning_rate": 0.1, "gamma": 0.1, "colsample_bytree": 0.7}

6. Visualizaciones

Las curvas ROC y matrices corresponden a predicciones del conjunto de prueba. Las importancias son propias de cada implementación (reducción de impureza para árboles de scikit-learn y la importancia expuesta por XGBoost); sus escalas no se deben comparar directamente ni interpretarse como efectos causales.

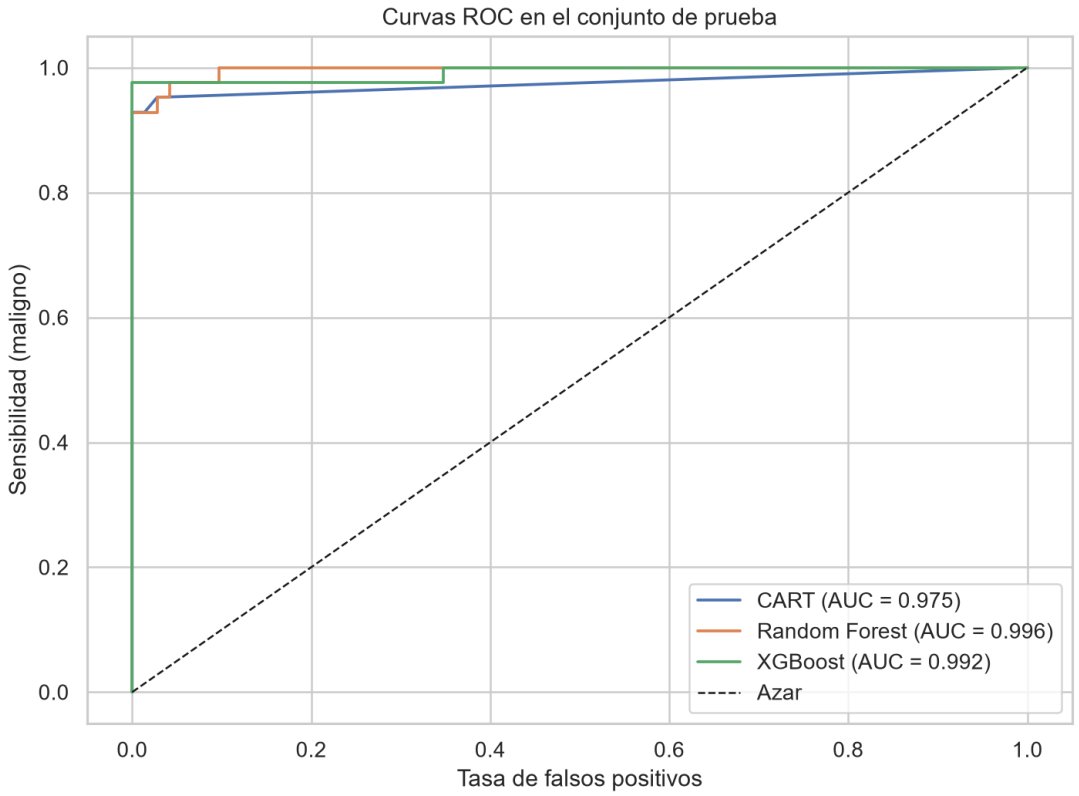


Figura 1. Curvas ROC de los tres modelos en los mismos datos de prueba.

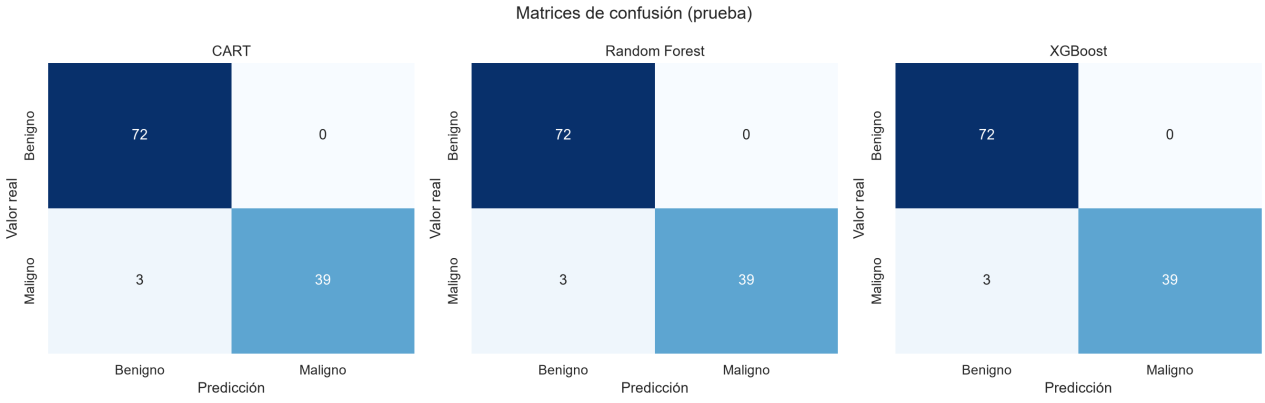


Figura 2. Matrices de confusión; la clase positiva es maligno.

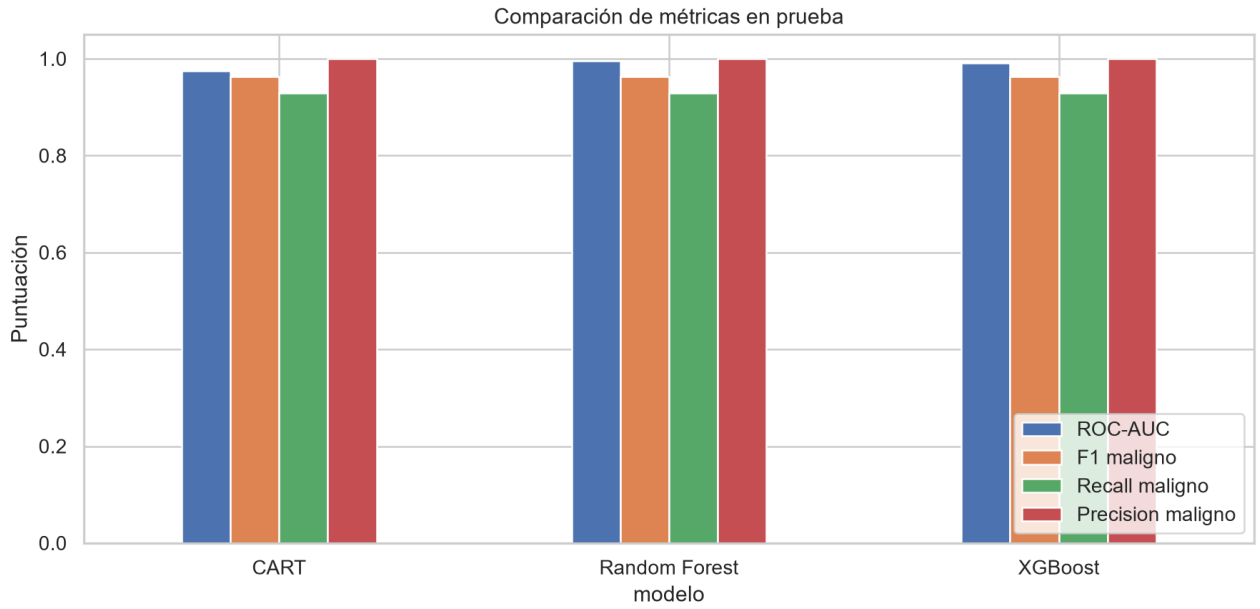


Figura 3. Comparación de ROC-AUC, F1, recall y precisión en prueba.

6.1 Importancia de variables y árbol interpretable

Las importancias muestran qué características fueron útiles para las particiones de estos modelos entrenados. CART se visualiza hasta profundidad 3 únicamente para facilitar la lectura; la figura no recorta el estimador utilizado para las métricas. Para una explicación de un caso individual se debe recorrer sus reglas hasta una hoja y tener en cuenta que el árbol puede ser inestable ante cambios en los datos.

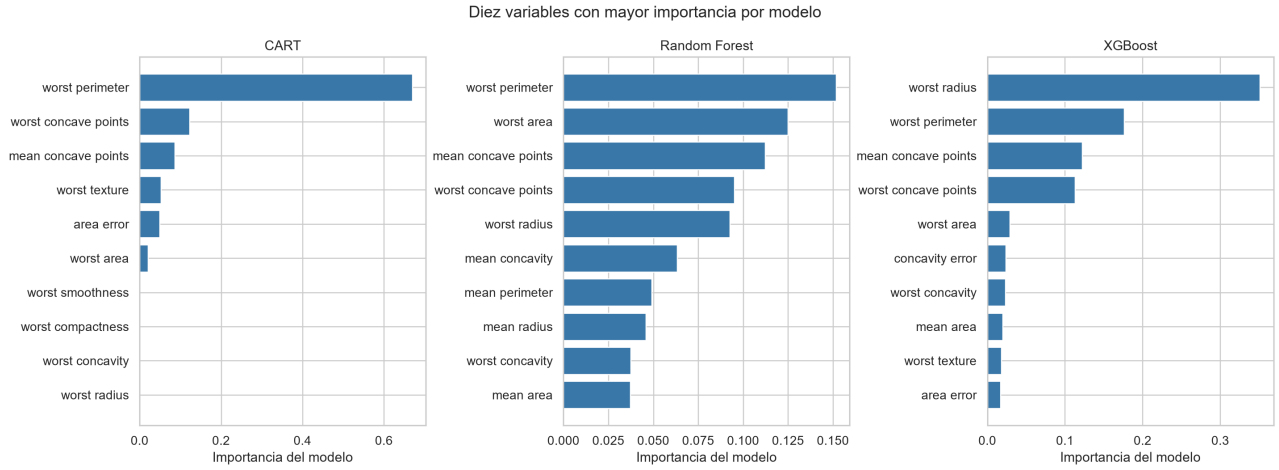


Figura 4. Diez variables de mayor importancia según cada modelo.

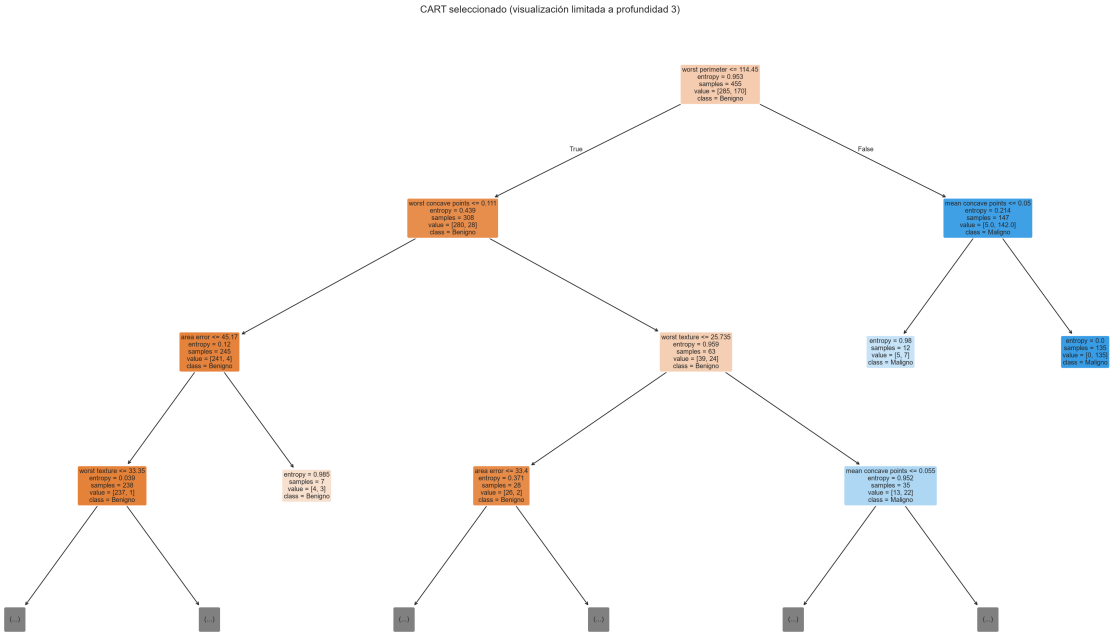


Figura 5. Árbol CART seleccionado, truncado visualmente a profundidad 3.

7. Aplicaciones y análisis crítico

CART — decisiones auditables

Un árbol pequeño puede apoyar la priorización de casos para revisión humana o la clasificación preliminar de registros estructurados, porque cada recorrido puede describirse con reglas. La profundidad limitada facilita comunicarlo, pero puede sacrificar desempeño y estabilidad. En salud, una regla aprendida de esta base histórica no es una guía clínica; debe validarse en población y entorno de uso.

Random Forest — patrones tabulares y robustez

El bagging suele ser útil en tareas tabulares como priorización de alertas de fraude, control de calidad o estimación de riesgo, cuando interesa estabilizar árboles individuales y modelar interacciones no lineales. El promedio hace menos transparente la explicación de una predicción individual y exige considerar falsos positivos, deriva y coste operativo.

XGBoost — ranking de riesgo tabular

El boosting regularizado es un candidato frecuente para clasificación tabular de alto rendimiento, por ejemplo para ordenar transacciones para revisión antifraude o priorizar expedientes. Puede capturar interacciones complejas, pero su ajuste es más delicado y su salida no es una explicación causal. Importancias o explicaciones locales requieren análisis adicional y validación.

En el experimento real de este trabajo, los tres algoritmos se evaluaron únicamente sobre el mismo problema WDBC. Los casos de fraude y riesgo mencionados son aplicaciones ilustrativas, no ensayos adicionales ni resultados medidos en esos dominios.

8. Simulación interactiva y entregables

La interfaz app.py permite seleccionar CART, Random Forest o XGBoost y obtener predicciones para ejemplos reservados de prueba o filas de un CSV con las 30 variables numéricas. Verifica columnas requeridas, valores numéricos y faltantes; presenta la clase y la probabilidad estimada de malignidad. Esa probabilidad no se interpreta como riesgo clínico calibrado.

El código reproducible se organiza en src/experiment.py y src/generate_report.py; los artefactos generados quedan en data/ y results/. Para ejecutar: instalar requirements.txt, correr python src\experiment.py, luego python src\generate_report.py y abrir streamlit run app.py.

9. Limitaciones, uso responsable y próximos pasos

El dataset es pequeño, histórico y procede de una fuente de imágenes y población específicas; no contiene suficiente contexto clínico para decisiones reales. Una partición aleatoria no sustituye validación externa ni prueba temporal. ROC-AUC no define el umbral adecuado; los costes de falsos negativos y falsos positivos se deben acordar con profesionales antes de cualquier uso. La probabilidad de un árbol/ensamble puede no estar calibrada. No se midieron intervalos de confianza, calibración, impacto de subgrupos ni robustez ante deriva. No se debe usar esta simulación en diagnóstico, tratamiento o triaje clínico.

Siguientes pasos para un estudio no académico: validación externa independiente; estimación de incertidumbre; análisis por subgrupos; calibración probabilística; selección prospectiva del umbral mediante análisis de costes y revisión ética/regulatoria.

10. Conclusiones

En esta partición, Random Forest obtuvo el mayor ROC-AUC de prueba (0.996). El resultado no implica que siempre supere a los otros modelos ni establece superioridad clínica. El modelo con mayor recall de malignos fue CART (0.929); por eso la elección depende del balance entre sensibilidad, precisión, explicabilidad, costes y validación apropiada. La evaluación común y la prueba separada permiten una comparación más justa que entrenar cada modelo con particiones diferentes.

Referencias

[1] UCI Machine Learning Repository. Breast Cancer Wisconsin (Diagnostic). https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic

[2] scikit-learn. load_breast_cancer: dataset loader and source attribution. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html

[3] scikit-learn. Decision Trees — classification, impurity and pruning. https://scikit-learn.org/stable/modules/tree.html

[4] Breiman, L., Friedman, J. H., Olshen, R. A. & Stone, C. J. (1984). Classification and Regression Trees. Chapman & Hall/CRC.

[5] Breiman, L. (2001). Random Forests. Machine Learning, 45, 5–32. https://doi.org/10.1023/A:1010933404324

[6] XGBoost contributors. Introduction to Boosted Trees. https://xgboost.readthedocs.io/en/stable/tutorials/model.html

[7] Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics, 29(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

[8] scikit-learn. Model evaluation: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html

Entorno registrado en la ejecución: Python 3.13.7, scikit-learn 1.9.0, XGBoost 3.4.1, pandas 3.0.5, NumPy 2.5.2. Las ejecuciones pueden variar levemente según versiones de bibliotecas y hardware.